Bonzi Trinidad, Elsener Guadalupe.
Inteligencia Artificial.
Ingeniería en Informática.
Universidad Católica de Santiago del Estero.

PrestaMatch: Optimización de cartera de préstamos P2P - Informe Final

1- Planteamiento del problema:

El objetivo de este proyecto fue desarrollar modelos de aprendizaje automático capaces de estimar la probabilidad de pago de los solicitantes de préstamos de PrestaMatch. A partir de estas probabilidades, buscamos seleccionar las solicitudes que permitieran obtener una mayor rentabilidad, respetando un presupuesto máximo de USD 2.000.000.

Por lo tanto, no nos enfocamos únicamente en la capacidad de clasificación de los modelos, sino también en su utilidad para tomar decisiones de aprobación de préstamos.

2 - Análisis y preparación de los datos:

Trabajamos con los tres archivos otorgados: “solicitudes_train” con 32.416 registros que contienen las solicitud históricas y su resultado final; “solicitudes_test” con 3.061 solicitudes utilizadas para generar las predicciones finales y “comportamiento_bancario” con 661.139 registros de historial bancario de los usuarios.

Antes de entrenar los modelos, realizamos un Análisis Exploratorio de Datos (EDA). Revisamos las dimensiones de los conjuntos, las primeras filas, las categorías, las estadísticas descriptivas, los tipos de datos, si había valores faltantes y los posibles registros duplicados. Esto nos permitió conocer la estructura de los datos antes de construir los modelos.

Luego incorporamos información del historial bancario de cada solicitante. Calculamos el saldo máximo, mínimo y promedio, los atrasos promedio y máximos en otras deudas y la cantidad de meses de historial disponibles. Para evitar utilizar información futura, consideramos únicamente los registros bancarios anteriores a la fecha de cada solicitud. Cuando no existía historial previo, asignamos cero a estas variables.

3 - Preprocesado:

Preparamos las variables para que pudieran ser utilizadas. Contemplamos el escaldado de las variables numéricas y la codificación de las variables categóricas mediante One-Hot Encoding. Organizamos estas operaciones junto con los modelos en un pipeline, para mantener el mismo tratamiento de los datos durante el entrenamiento y la predicción.

Para el preprocesamiento, configuramos una imputación por mediana para las variables numéricas y por el valor más frecuente para las variables categóricas. Si bien durante el análisis exploratorio no detectamos valores nulos en los conjuntos originales, incorporamos estas técnicas como medida preventiva para el tratamiento de posibles valores faltantes durante el procesamiento de los datos.

4 - Modelos y experimentos realizados:

Probamos distintos modelos: Regresión logística, Árboles de decisión, Random Forest y K-Nearest Neighbors (KNN). Finalmente, seleccionamos Regresión Logística y Random Forest para las entregas.

- ★ **Regresión logística:** Utilizamos como variables predictoras el monto solicitado, la tasa de interés, el ingreso mensual, las variables del historial bancario y el motivo del préstamo. Configuramos el peso de la clase como “balanceado” para considerar el desequilibrio entre las clases.

  Dividimos temporalmente los datos: entrenamos con solicitudes anteriores a noviembre de 2025 y validamos con las solicitudes de noviembre y diciembre. Evaluamos el modelo mediante AUC y accuracy. También calculamos la ganancia

esperada de los préstamos y seleccionamos los de mayor rendimiento sin superar el presupuesto.

★ **Random Forest:** Utilizamos las mismas variables predictoras. Al principio, configuramos el modelo con 200 árboles, una profundidad máxima de 10, un valor de 0.8 para la cantidad de variables consideradas en cada división y un ajuste para tener en cuenta el desequilibrio entre las clases. Luego, realizamos pruebas cambiando la cantidad mínima de registros que debía tener cada hoja del árbol a 20, 15 y 10, manteniendo los demás parámetros iguales.
Comparamos los resultados del entrenamiento y la validación para observar qué tan bien funcionaba el modelo con datos nuevos. También analizamos la rentabilidad de las aprobaciones, teniendo en cuenta la ganancia esperada, el capital utilizado, la ganancia real y el retorno sobre la inversión (ROI). Además, probamos otra división de los datos: utilizamos las solicitudes anteriores a septiembre de 2025 para entrenar y las de septiembre y octubre para validar.
Finalmente, entrenamos el modelo con todos los datos de entrenamiento disponibles y calculamos la probabilidad de pago de cada solicitud de prueba. Aprobamos los préstamos con ganancia esperada positiva, respetando el presupuesto disponible.

Los experimentos con Árboles de Decisión y KNN también formaron parte de la comparación. Sus puntuaciones finales fueron inferiores a las de los dos modelos seleccionados.

5 - Resultados:

Los resultados de las entregas evaluadas en Kaggle fueron los siguientes:

Modelo	Puntaje en Kaggle
Regresión logística (seleccionada)	**155.173,64**
Random Forest seleccionada)	**140.947,96**
Árboles de decisión	**127.282,61**
KNN	**46.974,82**

Finalmente, la Regresión Logística obtuvo el mejor puntaje en Kaggle, con 155173.64, seguida por Random Forest, con 140947.96. Por este motivo, seleccionamos ambos modelos para las entregas finales, priorizando los resultados obtenidos y la rentabilidad de los préstamos dentro del presupuesto disponible.